

# Chapitre 4

(Chapitre 2 de Sipser)

## Les langages hors-contexte

# Motivation

- description de langages plus intéressants que les langages réguliers
- préparation à l'étude de la compilation des langages de programmation
- ramifications en théorie de la complexité (classe LOGCFL, dépasse l'objet de ce cours)

## Grammaire hors-contexte

Exemple 4.1.

$$\begin{aligned} S &\rightarrow \varepsilon \\ &\quad | \langle \text{INCRÉMENTATION} \rangle S \\ &\quad | \langle \text{AFFECTATION} \rangle S \\ &\quad | \langle \text{RÉPÉTER} \rangle S \\ \langle \text{INCRÉMENTATION} \rangle &\rightarrow \text{inc}(V) \\ \langle \text{AFFECTATION} \rangle &\rightarrow V \leftarrow V \\ \langle \text{RÉPÉTER} \rangle &\rightarrow \text{répéter } V \text{ fois } [S] \\ V &\rightarrow r_N \\ N &\rightarrow C \mid CN \\ C &\rightarrow 0 \mid 1 \mid 2 \mid 3 \mid 4 \mid 5 \mid 6 \mid 7 \mid 8 \mid 9 \end{aligned}$$


Exemple 4.2.

$$\begin{aligned} \langle \text{PROGRAMME} \rangle &\rightarrow \text{program} \langle \text{ID} \rangle ; \\ &\quad \langle \text{DECL} \rangle \\ &\quad \langle \text{CORPS} \rangle \\ \langle \text{DECL} \rangle &\rightarrow \text{var} \langle \text{LISTE VAR} \rangle \\ \langle \text{LISTE VAR} \rangle &\rightarrow \langle \text{LISTE ID} \rangle : \langle \text{TYPE} \rangle ; \\ \langle \text{LISTE ID} \rangle &\rightarrow \langle \text{ID} \rangle \langle \text{AUTRES ID} \rangle \\ \langle \text{AUTRES ID} \rangle &\rightarrow \varepsilon \mid , \langle \text{ID} \rangle \langle \text{AUTRES ID} \rangle \\ &\quad \vdots \end{aligned}$$


**Définition 4.3.** (Sipser 2.2)

Une **grammaire hors contexte (GHC)** est un quadruplet  $(V, \Sigma, R, S)$  où :

- $V$  est un ensemble fini de **variables** ;
- $\Sigma$  est un alphabet fini, parfois appelé ensemble de **terminaux**, où  $V \cap \Sigma = \emptyset$  ;
- $R$  est un ensemble fini de **règles** de la forme  $A \rightarrow z$  où  $A \in V$  et  $z \in (V \cup \Sigma)^*$  ;
- $S \in V$  est la variable **initiale**.

▲

**Exemple 4.4.**

$$G = (V, \Sigma, R, S)$$

où

$$V = \{S, X\}$$

$$\Sigma = \{a, b, c\}$$

$$R = \{S \rightarrow SS \mid X \mid c, \quad X \rightarrow aXb \mid c\}.$$

$$V = \{S, X\}$$


$$\Sigma = \{a, b, c\}$$

$$R = \{S \rightarrow SS \mid X \mid c, \quad X \rightarrow aXb \mid c\}$$

Dérivation du mot **cacb** :

$$\begin{aligned} S &\Rightarrow SS \\ &\Rightarrow cS \\ &\Rightarrow cX \\ &\Rightarrow caXb \\ &\Rightarrow cacb \end{aligned}$$

## Arbre de dérivation de **cacb**



▲

Soit une GHC  $G = (V, \Sigma, R, S)$ .

Rappel : un **mot** est un élément de  $\Sigma^*$ .

**Définition 4.5.** Une **forme** est un élément de  $(V \cup \Sigma)^*$ . ▲

**Remarque 4.6.** "**hors-contexte**" car les règles régissent le remplacement d'une variable  $A$  dans  $uAv$  **indépendamment du contexte**  $uv$ . ▲

Soit  $G = (V, \Sigma, R, S)$  une GHC et soient  $u, v, w$  des formes.

**Définition 4.7.** On dit que  $uAv$  **donne**  $uwv$ , noté

$$uAv \Rightarrow uwv,$$

si  $A \rightarrow w$  est une règle de  $R$ .

On note  $u \xRightarrow{n} v$  si  $u$  donne  $v$  en  $n$  étapes :

$$u \Rightarrow u_1 \Rightarrow u_2 \Rightarrow \cdots \Rightarrow u_n = v.$$

Aussi,  $u \xRightarrow{*} v$  s'il existe un  $n \geq 0$  tel que  $u \xRightarrow{n} v$ . ▲

**Définition 4.8.** Soit  $G = (V, \Sigma, R, S)$  une GHC.

$$L(G) = \{w \in \Sigma^* \mid S \xRightarrow{*} w\}$$

est le **langage engendré** par  $G$ . ▲

**Définition 4.9.** Un langage  $Y$  est **hors-contexte** si il existe une GHC  $G$  telle que  $Y = L(G)$ . ▲

**Définition 4.10.** La classe des langages hors-contexte est notée **HC**. ▲

**Exemple 4.11.** Soit  $G = (\{S\}, \{a, b\}, R, S)$  où

$$R = \{S \rightarrow aSb \mid \varepsilon\}.$$

Alors

$$\begin{aligned} L(G) &= \{\varepsilon, ab, aabb, aaabbb, \dots\} \\ &= \{a^n b^n \mid n \geq 0\}. \end{aligned}$$

Dérivation du mot aaabbb par exemple :

$$\begin{aligned} S &\Rightarrow aSb \\ &\Rightarrow aaSbb \\ &\Rightarrow aaasbbb \\ &\Rightarrow aaabbb \end{aligned}$$

**Exemple 4.12.** Soit  $(V, \Sigma, R, S)$  la GHC où

$$\begin{aligned} V &= \{S, M, N\} \\ \Sigma &= \{0, 1, \dots, 9, +, *, (, )\} \\ R : \begin{cases} S &\rightarrow N \mid (S+S) \mid (S*S) \\ N &\rightarrow 1M \mid 2M \mid \dots \mid 9M \\ M &\rightarrow \varepsilon \mid 0M \mid 1M \mid \dots \mid 9M \end{cases} \end{aligned}$$

$$R : \begin{cases} S &\rightarrow N \mid (S+S) \mid (S*S) \\ N &\rightarrow 1M \mid 2M \mid \dots \mid 9M \\ M &\rightarrow \varepsilon \mid 0M \mid 1M \mid \dots \mid 9M \end{cases}$$

La variable  $N$  donne les nombres positifs :

$$N \Rightarrow 2M \Rightarrow 23M \Rightarrow 23.$$

Et  $S$  donne des expressions arithmétiques :

$$\begin{aligned} S &\Rightarrow (S+S) \Rightarrow (S+(S*S)) \\ &\stackrel{*}{\Rightarrow} (N+(N*N)) \\ &\stackrel{*}{\Rightarrow} (123 + (245 * 19)) \quad \blacktriangle \end{aligned}$$

**Exemple 4.13.** Soit  $G = (\{S\}, \{a, b\}, R, S)$  la GHC où

$$R : S \rightarrow aSb \mid bSa \mid SS \mid \varepsilon.$$

Quel est le langage  $L(G)$  ? ■

Vérifions que

$$L(G) = Y$$

où

$$Y = \{w : |w|_a = |w|_b\}.$$

$$R : S \rightarrow aSb \mid bSa \mid SS \mid \varepsilon$$

**Preuve.** Il est facile de voir que  $L(G) \subseteq Y$  car la partie droite de chaque règle ci-dessus est une forme  $\sigma$  telle que  $|\sigma|_a = |\sigma|_b$ .

Il reste à montrer que  $Y \subseteq L(G)$ . Prouvons par induction généralisée que pour tout  $n$ ,

$$w \in Y \text{ et } |w| = n \Rightarrow w \in L(G).$$

$$R : S \rightarrow aSb \mid bSa \mid SS \mid \varepsilon$$

**Base de l'induction.** Soit  $n = 0$ . Alors

$$w \in Y \text{ et } |w| = n \Rightarrow w = \varepsilon. \blacksquare$$

Or

$$S \Rightarrow \varepsilon$$

donc  $w \in L(G)$ .

$$R : S \rightarrow aSb \mid bSa \mid SS \mid \varepsilon$$

**Pas de l'induction généralisée.** Soit  $n > 0$ . Notre hypothèse d'induction est :

$$z \in Y \text{ et } |z| < n \Rightarrow S \xRightarrow{*} z. \blacksquare$$

Nous devons considérer  $w \in Y$  de longueur  $n$ .  
Remarquons que tous les mots  $w \in Y$  sont de longueur paire.  
Considérons 4 cas pour  $w$  :

$$R : S \rightarrow aSb \mid bSa \mid SS \mid \varepsilon$$

1)  $w = azb$ . Dans ce cas, on a la dérivation :

$$\begin{aligned} S &\Rightarrow aSb \\ &\xRightarrow{*} azb \quad (\text{par hypothèse d'induction}) \\ &= w. \end{aligned}$$

$$R : S \rightarrow aSb \mid bSa \mid SS \mid \varepsilon$$

2)  $w = bza$ . Alors

$$\begin{aligned} S &\Rightarrow bSa \\ &\xRightarrow{*} bza \quad (\text{par hypothèse d'induction}) \\ &= w. \end{aligned}$$

$$R : S \rightarrow aSb \mid bSa \mid SS \mid \varepsilon$$

3)  $w = aza$ . Dans ce cas,  $z$  contient deux  $b$  de plus que de  $a$ , et on peut donc le décomposer en  $z = z_1 \cdot z_2$ , où  $z_1$  et  $z_2$  contiennent chacun un  $b$  de plus que de  $a$ . D'où :

$$\begin{aligned} S &\Rightarrow SS \\ &\xRightarrow{*} az_1S \quad (\text{car } az_1 \in Y \text{ et par hyp. d'ind.}) \\ &\xRightarrow{*} az_1z_2a \quad (\text{car } z_2a \in Y \text{ et par hyp. d'ind.}) \\ &= aza \\ &= w. \end{aligned}$$

$$R : S \rightarrow aSb \mid bSa \mid SS \mid \varepsilon$$

4)  $w = bzb$ . Ce cas se traite comme le cas 3 *mutatis mutandis*.

Dans tous les cas, on a  $w \in L(G)$ . ▲

## Construction de grammaires

Construire une GHC pour un langage donné demande souvent de la créativité.

Cependant, un certain nombre de techniques peuvent aider, dont :

- décomposer le langage en l'union de deux langages plus simples ;
- utiliser des règles qui produisent des suites.

**Exemple 4.14.** Soit

$$Y = \{a^i b^j a^k b^l \mid (i = k \text{ ou } i = l); j \geq 0; k, l \geq 1\},$$

c'est-à-dire :

$$Y = \{a^i b^j a^i b^l \mid i \geq 1, j \geq 0, l \geq 1\} \\ \cup \{a^i b^j a^k b^i \mid i \geq 1, j \geq 0, k \geq 1\}.$$

Une GHC pour  $Y$  est donnée par :

$$G = (\{S, S_1, S_2, A, B, C, D\}, \{a, b\}, R, S)$$

avec

$$R : \begin{cases} S \rightarrow S_1 \mid S_2 \\ S_1 \rightarrow CbB \\ C \rightarrow aCa \mid aBa \\ B \rightarrow bB \mid \varepsilon \\ S_2 \rightarrow aS_2b \mid aDb \\ D \rightarrow BaA \\ A \rightarrow aA \mid \varepsilon \end{cases} \blacktriangle$$

## Ambiguïté

**Définition 4.15.** Un mot  $w$  est ambigu selon une GHC  $G$  s'il possède au moins deux arbres de dérivation distincts selon  $G$ . ▲




**Remarque 4.16.** Un arbre de dérivation de  $w$  donne lieu à plusieurs dérivations de  $w$ , mais à une seule dérivation de  $w$  à gauche. ▲

**Définition 4.17.** (Sipser 2.7) Une **GHC**  $G$  est **ambiguë** s'il existe un mot  $w \in L(G)$  qui est ambigu selon  $G$ . ▲

**Exemple 4.18.** La GHC  $(\{S\}, \{a, +, \times\}, R, S)$  avec  $R$  donné par

$$S \rightarrow S \times S \mid S + S \mid a$$

est une grammaire ambiguë.



**Définition 4.19.** Un langage hors-contexte  $Y$  est **essentiellement ambigu** si toute **GHC**  $G$  telle que  $L(G) = Y$  est ambiguë. ▲

**Exemple 4.20.**  $\{a^i b^j c^k : i = j \text{ ou } j = k\}$  est un langage essentiellement ambigu. ▲

**Remarque 4.21.** Prouver qu'un langage est essentiellement ambigu n'est pas une mince tâche ! ▲

## Forme normale de Chomsky

Jusqu'où peut-on simplifier une GHC sans changer le langage qu'elle décrit ?

**Définition 4.22.** (Sipser 2.8)  $(V, \Sigma, R, S)$  est une grammaire **en forme normale de Chomsky** (une **GFNC**) si... ▲



...toutes ses règles sont

de la forme  $A \rightarrow BC$   
ou de la forme  $A \rightarrow a$

avec

$A, B, C \in V,$   
 $B \neq S,$   
 $C \neq S,$   
 $a \in \Sigma,$

en permettant aussi

$S \rightarrow \varepsilon.$



**Théorème 4.23.** (Sipser 2.9) Tout langage hors-contexte est  $L(G)$  pour une certaine GFNC  $G$ .

**Aperçu de la preuve.** Exhibons un algorithme qui prend en entrée une GHC  $G$  et qui retourne une GFNC  $G'$  telle que  $L(G) = L(G')$ :

## Algorithme de conversion d'une GHC en forme normale de Chomsky

En entrée :  $G = (V, \Sigma, R, S)$ , une GHC.

1. Ajouter la nouvelle variable initiale  $S_0$  à  $V$  et ajouter la règle  $S_0 \rightarrow S$  à  $R$ .

2. Éliminer de  $R$  toutes les règles de la forme  $A \rightarrow \varepsilon$ , sauf possiblement la règle  $S_0 \rightarrow \varepsilon$ , en **itérant** les étapes suivantes :

2.1. Enlever  $A \rightarrow \varepsilon$ .

2.2. Pour toute règle  $B \rightarrow uAv$  faire :

ajouter  $B \rightarrow uv$ , à moins que  $uv = \varepsilon$  et que la règle  $B \rightarrow \varepsilon$  ait déjà été traitée en 2.1.

3. Éliminer de  $R$  toutes les règles unitaires, ie de la forme  $A \rightarrow B$  où  $B \in V$ , en **itérant** les étapes suivantes :

3.1. Enlever  $A \rightarrow B$ .

3.2. Pour toute règle  $B \rightarrow w$  faire :  
ajouter  $A \rightarrow w$ , à moins que  $w \in V$  et que la règle  $A \rightarrow w$  ait déjà été traitée en 3.1.

4. Éliminer de  $R$  toutes les règles de la forme

$$A \rightarrow u_1 u_2 \dots u_k$$

où  $k \geq 3$  et où  $u_1, u_2, \dots, u_k \in V \cup \Sigma$  :

4.1. Enlever  $A \rightarrow u_1 u_2 \dots u_k$ .

4.2. Ajouter  $A_1, A_2, \dots, A_{k-2}$  à  $V$ .

4.3. Ajouter les règles

$$\begin{aligned} A &\rightarrow u_1 A_1 \\ A_1 &\rightarrow u_2 A_2 \\ &\dots \\ A_{k-2} &\rightarrow u_{k-1} u_k. \end{aligned}$$

5. Éliminer de  $R$  toutes les règles de la forme  $A \rightarrow aB$  où  $a \in \Sigma$  et  $B \in V$  :

5.1. Enlever  $A \rightarrow aB$ .

5.2. Ajouter  $A'$  à  $V$ .

5.3. Ajouter les règles  $A \rightarrow A'B$  et  $A' \rightarrow a$ .

Idem pour les règles de la forme  $A \rightarrow Ba$ .

Le résultat est la GFNC  $G'$ . ▲

**Exemple 4.24.**

$$G = (\{S, A, B\}, \{a, b\}, R, S)$$

où

$$R : \begin{cases} S &\rightarrow ASA \mid aB \\ A &\rightarrow B \mid S \\ B &\rightarrow b \mid \varepsilon \end{cases}$$

Étape 1. Ajouter une nouvelle variable initiale.

Avant :

$$\begin{aligned} S &\rightarrow ASA \mid aB \\ A &\rightarrow B \mid S \\ B &\rightarrow b \mid \varepsilon \end{aligned}$$

Après :

$$\begin{aligned} S_0 &\rightarrow S \\ S &\rightarrow ASA \mid aB \\ A &\rightarrow B \mid S \\ B &\rightarrow b \mid \varepsilon \end{aligned}$$

Étape 2. Éliminer les règles  $\varepsilon$ .

Avant :

$$\begin{aligned} S_0 &\rightarrow S \\ S &\rightarrow ASA \mid aB \\ A &\rightarrow B \mid S \\ B &\rightarrow b \mid \varepsilon \end{aligned}$$

Après :

$$\begin{aligned} S_0 &\rightarrow S \\ S &\rightarrow ASA \mid aB \mid a \mid SA \mid AS \\ A &\rightarrow B \mid S \\ B &\rightarrow b \end{aligned}$$

Étape 3. Éliminer les règles unitaires.

Avant :

$$\begin{aligned} S_0 &\rightarrow S \\ S &\rightarrow ASA \mid aB \mid a \mid SA \mid AS \\ A &\rightarrow B \mid S \\ B &\rightarrow b \end{aligned}$$

Après :

$$\begin{aligned} S_0 &\rightarrow ASA \mid aB \mid a \mid SA \mid AS \\ S &\rightarrow ASA \mid aB \mid a \mid SA \mid AS \\ A &\rightarrow b \mid ASA \mid aB \mid a \mid SA \mid AS \\ B &\rightarrow b \end{aligned}$$

Étape 4. Éliminer les règles à formes trop longues.

Avant :

$$\begin{aligned} S_0 &\rightarrow ASA \mid aB \mid a \mid SA \mid AS & A &\rightarrow b \mid ASA \mid aB \mid a \mid SA \mid AS \\ S &\rightarrow ASA \mid aB \mid a \mid SA \mid AS & B &\rightarrow b \end{aligned}$$

Après :

$$\begin{aligned} S_0 &\rightarrow aB \mid a \mid SA \mid AS \mid AS_{0,1} & A &\rightarrow b \mid aB \mid a \mid SA \mid AS \mid AA_1 \\ S_{0,1} &\rightarrow SA & A_1 &\rightarrow SA \\ S &\rightarrow aB \mid a \mid SA \mid AS \mid AS_1 & B &\rightarrow b \\ S_1 &\rightarrow SA \end{aligned}$$

Étape 5. Éliminer les règles mixtes.

Avant :

$$\begin{array}{ll} S_0 \rightarrow aB \mid a \mid SA \mid AS \mid AS_{0,1} & A \rightarrow b \mid aB \mid a \mid SA \mid AS \mid AA_1 \\ S_{0,1} \rightarrow SA & A_1 \rightarrow SA \\ S \rightarrow aB \mid a \mid SA \mid AS \mid AS_1 & B \rightarrow b \\ S_1 \rightarrow SA & \end{array}$$

Après :

$$\begin{array}{ll} S_0 \rightarrow S'_0 B \mid a \mid SA \mid AS \mid AS_{0,1} & S_1 \rightarrow SA \\ S'_0 \rightarrow a & A \rightarrow b \mid A'B \mid a \mid SA \mid AS \mid AA_1 \\ S_{0,1} \rightarrow SA & A' \rightarrow a \\ S \rightarrow S'B \mid a \mid SA \mid AS \mid AS_1 & A_1 \rightarrow SA \\ S' \rightarrow a & B \rightarrow b \end{array}$$

**Remarque 4.25.** L'exemple précédent peut être simplifié à la GFHC suivante :

$$\begin{array}{l} S_0 \rightarrow DB \mid a \mid SA \mid AS \mid AC \\ S \rightarrow DB \mid a \mid SA \mid AS \mid AC \\ A \rightarrow b \mid DB \mid a \mid SA \mid AS \mid AC \\ B \rightarrow b \\ C \rightarrow SA \\ D \rightarrow a \end{array}$$

▲

## Deux évidences sur une grammaire en forme normale de Chomsky

Soit  $G = (V, \Sigma, R, S)$  une GFNC.

**Remarque 4.26.** Si  $a \in \Sigma \cup \{\varepsilon\}$  et  $a \in L(G)$ , alors forcément

$$S \rightarrow a$$

est une règle de  $G$ .

▲

## Deux évidences (suite et fin)

**Remarque 4.27.** Si  $A \in V$  et  $A \xRightarrow{*} w_1 w_2 \dots w_n$  où  $n > 1$ , alors forcément  $A \xRightarrow{*} BC$  où  $B, C \in V$  et

$$B \xRightarrow{*} w_1 w_2 \dots w_{i-1}$$

et

$$C \xRightarrow{*} w_i w_{i+1} \dots w_n$$

pour un certain  $1 < i \leq n$ .

▲

## Appartenance d'un mot à un langage hors-contexte

**Théorème 4.28.** Il existe un algorithme qui prend en entrée un mot  $w$  et une GHC  $G$  et qui détermine si  $w \in L(G)$ .

**Preuve.**

Étape 1 : mettre en forme de Chomsky.

Étape 2 : si  $w \neq \varepsilon$ , dire oui ssi  $S \xRightarrow{*} w$ ,  
où  $n = 2|w| - 1$ . (Pourquoi ça marche ?) ■

**Remarque 4.29.** Pas brillant ! ▲

## Un bien meilleur algorithme

**Théorème 4.30.** Pour  $G$  fixée, il est possible de déterminer si  $w_1 w_2 \dots w_n \in L(G)$  en temps  $O(n^3)$ .

**Aperçu de la preuve.**

Étape 1 : supposer  $(V, \Sigma, R, S)$  une GFNC.

Étape 2 : construire un tableau  $T$  dont l'entrée  $(i, j)$ ,  $1 \leq i \leq j \leq n$ , contient

$$\{A \in V : A \xRightarrow{*} w_i w_{i+1} \dots w_j\}.$$

Étape 3 : accepter  $w_1 w_2 \dots w_n$  ssi  $S \in T(1, n)$ . ■

## Pour les curieux(x + ses)

Le tableau  $T$  se construit par balayage en partant de la diagonale principale.

C'est une application classique de la technique de la programmation dynamique.

**Remarque 4.31.** Lorsque  $G$  est la grammaire d'un langage de programmation, l'analyse syntaxique d'un mot  $w \in L(G)$  est la première tâche d'un compilateur de ce langage. ▲

En réalité, des propriétés plus fines que "hors-contexte" sont exploitées pour la compilation car  $O(n^3)$  serait trop inefficace.

Par ailleurs, l'analyse syntaxique est compliquée du fait de devoir

- détecter sans délai les erreurs de syntaxe,
- interagir avec l'analyse sémantique.

**Théorème 4.32.**


REG  $\subseteq$  HC

**Preuve.** Un langage régulier est  $L(M)$  pour un AFD  $M = (Q, \Sigma, \delta, q_0, F)$ . On voit facilement que

$$\begin{aligned} V &= Q, \\ R &= \{(A \rightarrow xB) : A, B \in Q, x \in \Sigma, \delta(A, x) = B\} \\ &\quad \cup \{(A \rightarrow \varepsilon) : A \in F\} \text{ et} \\ S &= q_0 \end{aligned}$$

définissent une GHC  $G = (V, \Sigma, R, S)$  qui vérifie  $L(G) = L(M)$ .

Exemple de cette construction :



$G = (\{A, B, C\}, \{a, b\}, R, A)$  où  $R$  est défini par

$$\begin{aligned} A &\rightarrow aB \mid bC \\ B &\rightarrow bB \mid aC \mid \varepsilon \\ C &\rightarrow bA \mid aC \mid \varepsilon. \end{aligned} \quad \blacktriangle$$

**Corollaire 4.33.** La classe REG est strictement incluse dans la classe HC.

**Preuve.** Soit  $Y = \{a^n b^n \mid n \geq 0\}$ .

Nous avons vu en exemple que  $Y$  est hors-contexte, et au chapitre précédent que  $Y$  n'est pas régulier. ■

## Peut-on montrer qu'un langage n'est PAS hors-contexte ?


Intuition : une GHC peut balancer des parenthèses à l'aide de

$$A \rightarrow (A) \Rightarrow ((A)) \Rightarrow (((A))) \Rightarrow \underbrace{((\dots(A)))}_{n \text{ fois}} \underbrace{\dots}_{n \text{ fois}}$$

mais pourrait-elle en même temps compter  $n$  répétitions d'un 3ième symbole, par exemple

$$A \xrightarrow{*} \underbrace{((\dots(}_{n \text{ fois}} \underbrace{\$ \$ \dots \$)}_{n \text{ fois}} \underbrace{)) \dots)}_{n \text{ fois}} ?$$

**Lemme du bonhomme Michelin à cinq pneus**  
(dixit Claude Christen)  
(alias "du Michelin hors-contexte")  
(alias "du pompiste hors-contexte")  
(alias "Pumping lemma for context-free languages")



(<http://tcpneus.france.com/tcpneus/images/Classic%20serie%2080.jpg>)  
([http://www.polarsolid.com/solid\\_tires\\_picture\\_6.htm](http://www.polarsolid.com/solid_tires_picture_6.htm))

## Énoncé formel du lemme du Michelin hors-contexte

**Lemme 4.34.** (Sipser 2.34)


Soit  $Y \in \text{HC}$ . Il existe un entier  $p \geq 1$  tel que pour tout  $w \in Y$  vérifiant  $|w| \geq p$ , on peut écrire  $w = uvxyz$  de manière à ce que

- $|vy| > 0$  et
- $|vxy| \leq p$  et
- $uv^i xy^i z \in Y$  pour tout  $i \geq 0$ .

### Aperçu de la preuve.

Si un mot  $w \in Y$  est suffisamment long, alors il aura un arbre de dérivation très haut.

Cet arbre possèdera un chemin, du sommet à une feuille, avec répétition d'une certaine variable, disons  $A$ , comme ci-dessous :



### Exemple 4.35. Le langage

$$Y = \{a^n b^n c^n \mid n \geq 0\}$$

n'est pas hors-contexte.

#### Preuve.

Supposons au contraire que  $Y \in \text{HC}$ .

Soit  $p \geq 1$  tel que fourni par le lemme du Michelin hors contexte.

Prenons le mot  $w = a^p b^p c^p$ .

On a bien  $w \in Y$  et  $|w| = 3p \geq p$ .

Est-il possible de décomposer  $w$  en  $uvxyz$  tout en respectant  $|vy| > 0$  et  $|vxy| \leq p$  et  $uv^i xy^i z \in Y$  pour tout  $i \geq 0$ ?



Essayons. Regroupons les cas possibles d'une décomposition  $w = uvxyz$  vérifiant déjà  $|vy| > 0$  et  $|vxy| \leq p$ . ■

**Cas 1.** Le sous-mot  $v$  ou le sous-mot  $y$  contient plus d'une sorte des symboles  $a$ ,  $b$  ou  $c$ . ■

Alors  $uv^2xy^2z$  n'est forcément pas de la forme  $a^n b^n c^n$  (pourquoi?)

Donc aucune des décompositions du présent cas ne satisfait  $uv^i xy^i z \in Y$  pour tout  $i$ .

**Cas 2.** Les sous-mots  $v$  et  $y$  contiennent chacun une seule sorte de symbole.

Alors  $uv^0 xy^0 z = uxz$  n'est forcément pas de la forme  $a^n b^n c^n$  (pourquoi?)

Donc aucune des décompositions du cas 2 ne satisfait  $uv^i xy^i z \in Y$  pour tout  $i$ . ■

Puisque toutes les décompositions pertinentes de  $w$  en  $uvxyz$  violent la promesse du lemme, nous obtenons la contradiction désirée.

Donc  $Y \notin \text{HC}$ . ▲

## Propriétés de fermeture

**Théorème 4.36.** HC est fermée sous l'union.

**Preuve.** Soient

$$\begin{aligned} L_1 &= L(G_1) \text{ où } G_1 = (V_1, \Sigma, R_1, S_1) \\ L_2 &= L(G_2) \text{ où } G_2 = (V_2, \Sigma, R_2, S_2) \end{aligned}$$

en supposant que  $V_1$  et  $V_2$  sont disjoints, de même que  $R_1$  et  $R_2$ .

Alors la GHC suivante :

$$G = (V_1 \cup V_2 \cup \{S\}, \Sigma, R_1 \cup R_2 \cup \{S \rightarrow S_1 \mid S_2\}, S)$$

engendre le langage  $L_1 \cup L_2$ . ■

## Surprise

**Théorème 4.37.** La classe HC n'est pas fermée sous l'intersection.

**Preuve.** Soient

$$\begin{aligned} L_1 &= \{a^m b^n c^n \mid m \geq 0, n \geq 0\}, \\ L_2 &= \{a^n b^n c^m \mid m \geq 0, n \geq 0\}. \end{aligned}$$

Alors

$$L_1 \cap L_2 = \{a^n b^n c^n \mid n \geq 0\}.$$

Or nous avons démontré en exemple que ce langage n'est pas hors-contexte. ■

## Sur...prise II

**Théorème 4.38.** La classe HC n'est pas fermée sous la complémentation.


**Preuve.** Supposons au contraire que HC est fermée sous la complémentation.

Alors HC est fermée sous intersection puisque HC est fermée sous union (théorème 4.36) et pour tout  $L_1$  et  $L_2$ ,

$$L_1 \cap L_2 = \overline{\overline{L_1} \cup \overline{L_2}}.$$

Ceci contredit le théorème 4.37. ■

## Le monde des langages, prise 2



## Un modèle de type "automate" pour les langages hors-contexte


Que manquerait-il à un automate fini pour être capable de reconnaître, par exemple, le langage non régulier  $\{ww^R : w \in \{a, b\}^*\}$  ?

On aimerait :

- préserver le nombre fini d'états
- préserver le parcours de droite à gauche du mot lu.

Réponse : une pile !

## L'automate à pile vu informellement



## L'automate à pile vu formellement

**Définition 4.39.** (Sipser 2.13)

Un **automate à pile non déterministe (APN)** est un 6-tuplet  $(Q, \Sigma, \Gamma, \delta, q_0, F)$  où

- $Q, \Sigma, q_0, F \subseteq Q$  sont comme pour un AFD,
- $\Gamma$  est l'**alphabet de pile** (fini),
- $\delta : Q \times \Sigma_\epsilon \times \Gamma_\epsilon \rightarrow P(Q \times \Gamma_\epsilon)$  est la **fonction de transition**.

▲

## Fonctionnement de l'automate à pile

Si  $(q, Z) \in \delta(p, a, X)$  et

- $p$  est l'état courant et
- $a$  est le prochain symbole de l'entrée et
- $X$  est sur le dessus de la pile,

alors

une des transitions possibles consiste à

- dépiler  $X$  et
- empiler  $Z$  et
- passer de l'état  $p$  à l'état  $q$ .

**Remarque 4.40.** Pour accepter, un APN doit

atteindre un état final  
et  
avoir lu toute son entrée.

▲


■

**Définition 4.41.** Soit  $M$  un APN. Alors  $L(M) = \{w : M \text{ accepte } w\}$  est le **langage accepté** par  $M$ .

▲

**Exemple 4.42.**

$M = (\{q_1, q_2, q_3, q_4\}, \{0, 1\}, \{0, \$\}, \delta, q_1, \{q_1, q_4\})$  où  $\delta$  est défini par



On a  $L(M) = \{0^n 1^n : n \geq 0\}$ .

▲

## Deux faits sans preuve

**Théorème 4.43.** (Sipser 2.20) Un langage  $Y$  est hors-contexte ssi  $Y = L(\text{un APN } M)$ . ■

**Définition 4.44.** Une restriction naturelle imposée au  $\delta$  de l'APN donne l'**automate à pile déterministe (APD)**. ▲

**Théorème 4.45.** Aucun APD n'accepte

$$\{ww^R : w \in \{a, b\}^*\}$$

mais un APD accepte sur alphabet  $\{a, b, c\}$

$$\{wcw^R : w \in \{a, b\}^*\}.$$

■

## Un modèle de type “grammaire” pour les langages réguliers

Quelle restriction faudrait-il imposer aux GHCs pour capturer précisément la classe des langages réguliers ?

Déjà vu de manière implicite dans la preuve que  $\text{REG} \subseteq \text{HC}$  !

**Définition 4.46.** Une **grammaire linéaire à droite (GLD)** est une GHC où chaque règle contient au plus une variable, qui doit être le symbole **le plus à droite** de la règle ▲

**Définition 4.47.** Une **grammaire linéaire à gauche (GLG)** est une GHC où chaque règle contient au plus une variable, qui doit être le symbole **le plus à gauche** de la règle. ▲

## Grammaires régulières

**Définition 4.48.** Une grammaire linéaire à gauche ou linéaire à droite est appelée une **grammaire régulière**. ▲

**Théorème 4.49.** Un langage  $Y$  est régulier ssi  $Y = L(\text{une grammaire régulière})$ . ■

**Aperçu de la preuve.**

Déjà vu : simulation d'un AFD par une GLD.

Voyons maintenant la simulation d'une GLD par un AFNG :

Considérons une GLD  $G = (V, \Sigma, R, S)$ .

L'AFNG ci-dessous accepte  $L(G)$  :

$$M = (V \cup \{f\}, \Sigma, \delta, S, \{f\})$$


où  $\delta$  est défini par :

$$\begin{aligned} B \in \delta(A, w) & \text{ ssi } A \rightarrow wB \text{ est une règle,} \\ f \in \delta(A, w) & \text{ ssi } A \rightarrow w \text{ est une règle.} \end{aligned}$$

En réalité  $M$  est un AFN avec des mots pour transitions.

Exemple de cette construction :

$$\begin{aligned} S & \rightarrow abX \mid bY \mid Z \\ X & \rightarrow aY \mid bbb \\ Y & \rightarrow bY \mid bS \mid \varepsilon \\ Z & \rightarrow aY \mid bS \end{aligned}$$



## Pour les curieux + ses

### De GLG à AFN

1. Renverser les membres de droite des règles : GLD pour  $L^R$ .
2. Construire AFN pour GLD.
3. Renverser l'AFN (transitions, états finaux, état initial).

### De AFN à GLG

1. Renverser l'AFN.
2. Construire GLD.
3. Renverser les membres de droite des règles.

## Révision du chapitre

- GHC
- Preuve que  $L(G)$  est un certain langage
- Tout langage régulier est hors-contexte
- Lemme du pompiste hors-contexte
- Propriétés de fermeture et de non-fermeture
- Existence de l'automate à pile
- Existence des grammaires régulières